Квадрицепс. Тембр.

Анализ датасета.

Корпус содержит 807 974 аудиозаписи, включая 673 277 записей обучающей выборки и 134 697 записей публичной тестовой выборки. Техническая верификация корпуса включала проверку полноты файлового набора, согласованности соответствия между путями и идентификаторами говорящих, анализ заголовков аудиофайлов и контрольное декодирование записей. Проведенные проверки не выявили структурных дефектов корпуса: отсутствующие файлы, нарушения соответствия путей, ошибки заголовков и ошибки декодирования отсутствуют. Все записи имеют единый формат представления: 16 кГц, один канал, FLAC, PCM_16. Объем выбранных данных составляет 99.102 ГБ для обучающей части и 17.048 ГБ для публичной тестовой части. Распределения записей по длительности, представленные на рисунке 1, используются далее для анализа различий между обучающей и тестовой частями корпуса.

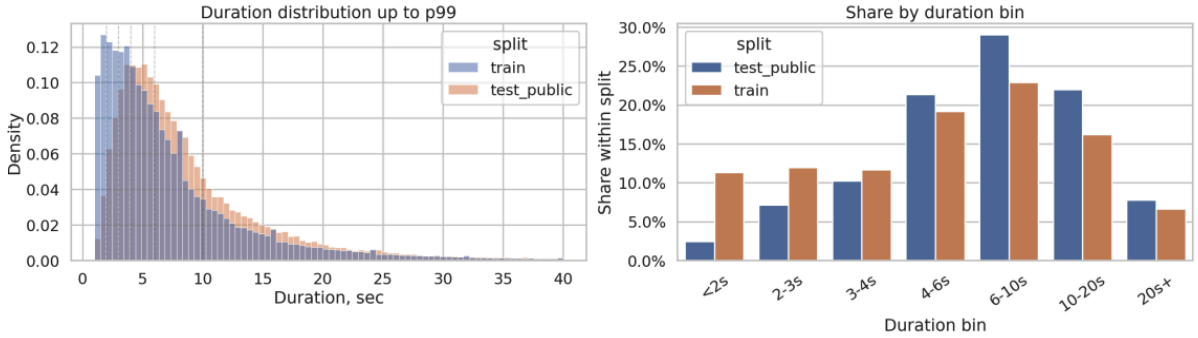

Рис. 1. Диаграммы распределения длительности аудиодорожек в датасете.

Анализ распределений длительностей показывает наличие выраженного различия между обучающей и тестовой частями корпуса:

обучающая выборка характеризуется повышенной концентрацией коротких записей, тогда как тестовая выборка содержит более протяженный правый хвост распределения. Это свидетельствует о необходимости адаптации методов обработки к различным диапазонам длительности: применения специальных приемов для коротких записей в процессе обучения и использования процедур сегментации или агрегации для длинных записей на этапе предсказания. Для уточнения структуры данного эффекта далее рассматриваются статистики длительности в разрезе спикеров, представленные на рисунке 2.

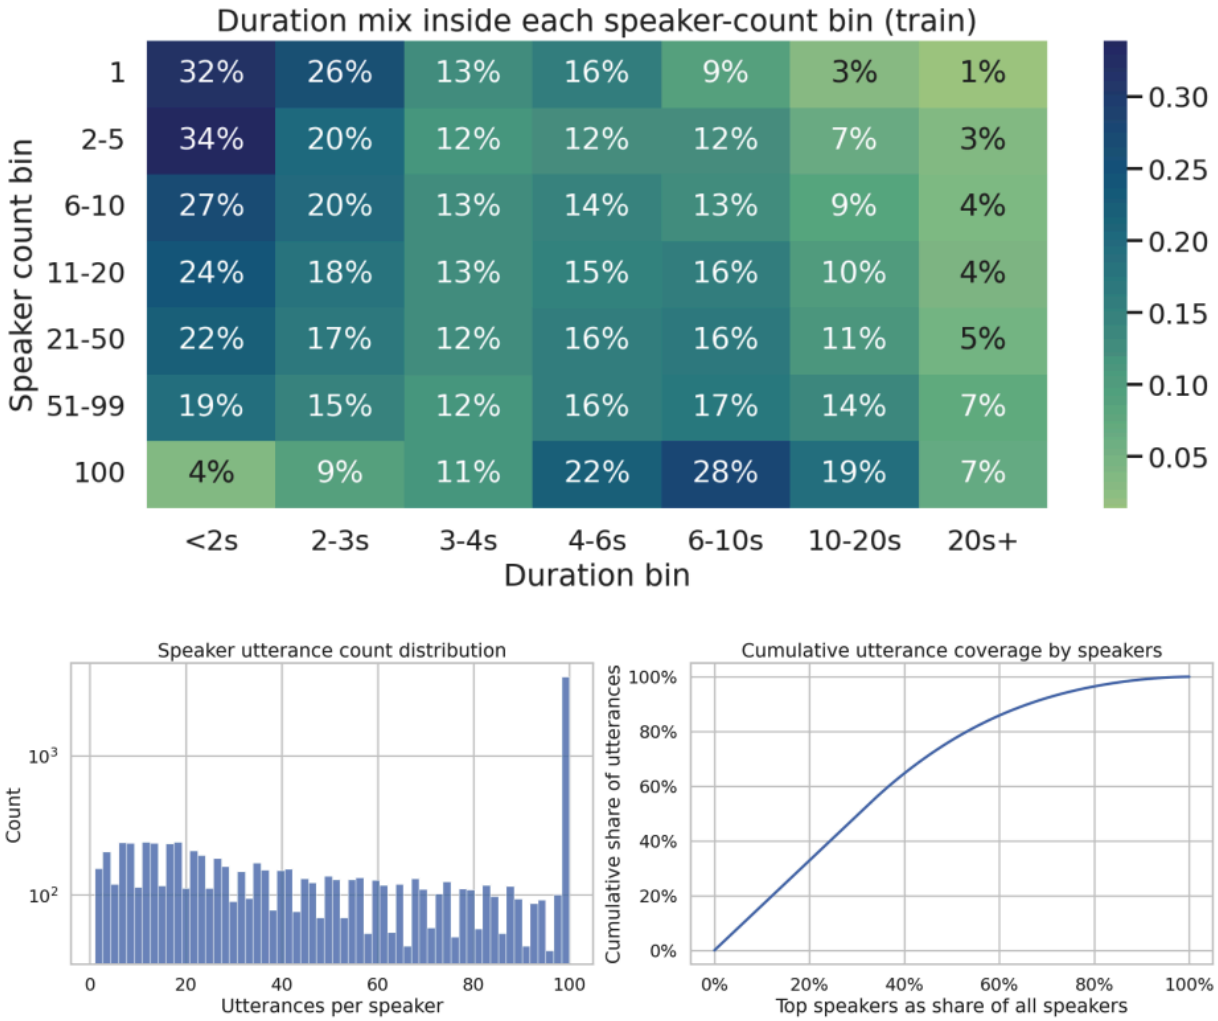

Рис. 2. Смешение длительностей внутри корзин по числу записей на говорящего и накопленное покрытие корпуса наиболее частыми говорящими.

Анализ распределений в разрезе говорящих показывает наличие двух существенных особенностей структуры корпуса. С одной стороны, распределение числа записей на одного говорящего имеет выраженный правый хвост, при этом в области около 100 записей наблюдается характерное накопление значений, вероятно связанное с особенностями формирования выборки. С другой стороны, для говорящих с малым числом примеров характерна более высокая доля коротких записей. Следовательно, неоднородность данных определяется не только дисбалансом классов, но и сопряженным различием в объеме доступного речевого материала. Это указывает на целесообразность использования стратегий балансировки семплирования по говорящим и на необходимость осторожной интерпретации результатов локальной валидации в условиях выраженной неравномерности корпуса.

Далее рассмотрим файловые акустические признаки корпуса. Для количественного сопоставления обучающей и тестовой выборок использовались три признака: доля активной речи, спектральная плоскостность и коэффициент высокочастотной энергии. Доля активной речи для записи (x) определялась как [2, 3]

$$r(x) = \frac{1}{T} \sum_{(a,b)\in\mathcal{I}(x)} (b-a),$$

где (T) — длительность записи в секундах, а $\mathcal{I}(x)$ — множество временных интервалов, признанных активными процедурой `librosa.effects.split` при фиксированных параметрах `top_db`, `frame_length` и

`hop_length`. В данной процедуре тишина задаётся не фонетическим детектором речевой активности и не абсолютным порогом в децибелах, а относительным энергетическим критерием: сигнал разбивается на короткие кадры, для каждого кадра вычисляется среднеквадратический уровень энергии, после чего кадр считается активным, если его уровень не ниже порога, заданного относительно максимальной энергии записи [2].

Спектральная плоскостность характеризует степень тональности или шумоподобия спектра и для кадра (m) вычисляется как отношение геометрического среднего спектральной мощности к арифметическому [3]:

$$SF_m = \frac{\left(\prod_{k=1}^{K}(P_m[k]+\varepsilon)\right)^{1/K}}{\frac{1}{K}\sum_{k=1}^{K}(P_m[k]+\varepsilon)},$$

где $P_m[k]$ — спектральная мощность на k-й частотной полосе в кадре m, K — число частотных полос, $\varepsilon > 0$ — малое регуляризующее число. Малые значения SF_m соответствуют выраженной тональной структуре спектра, тогда как большие значения указывают на более ровный, шумоподобный спектр.

Коэффициент высокочастотной энергии определялся как доля спектральной энергии, сосредоточенной выше фиксированной граничной частоты f_c:

$$HBR_m = \frac{\sum_{k:,f_k \geq f_c} P_m[k]}{\sum_{k=1}^{K} P_m[k] + \varepsilon},$$

где f_k — центральная частота k-й полосы, а f_c — граница высокочастотной области. Тем самым признак HBR_m количественно

описывает, насколько велика доля высокочастотной энергии в записи; меньшие значения соответствуют более узкополосному сигналу. На рисунке 3 приведено сравнение распределений указанных признаков в обучающей и тестовой выборках [3].

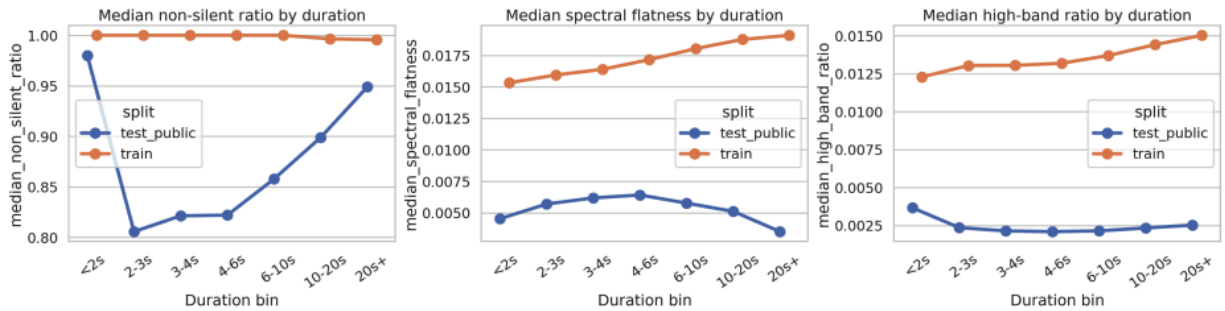

Рис. 3. Различия между обучающей и тестовой частями по доле участков активной речи, спектральной плоскостности и высокочастотной энергии.

Графики показывают, что тестовая часть не только длиннее, но и акустически отличается: в ней систематически больше пауз и меньше энергии в верхней полосе частот. Наблюдаемый акустический сдвиг мотивирует проверку аугментаций, имитирующих шум, реверберацию и ограничение полосы пропускания; их вклад далее оценивается в соответствующих экспериментах [12].

Экспериментальный протокол.

В работе рассматривается задача поиска записей того же говорящего внутри тестового множества. Для каждой записи-запроса $q \in Q$ система должна вернуть k других записей из того же множества, ранжированных по предполагаемой принадлежности тому же диктору. Тем самым решается

задача speaker retrieval, в которой запросу сопоставляется список из k ближайших соседей.

Основной внешней метрикой является Precision@k. Для каждого запроса q она определяется как доля корректных соседей среди первых k возвращённых записей:

$$P@k(q) = \frac{1}{k} \sum_{i=1}^{k} \mathbf{1}! \left[y_i(q) = y(q) \right],$$

где y(q) — истинный идентификатор говорящего для запроса q, $y_i(q)$ — идентификатор говорящего для i-го возвращённого соседа, а $\mathbf{1}(\cdot)$ — индикатор совпадения. Итоговая метрика по выборке вычисляется усреднением по всем запросам:

$$P@k = \frac{1}{|Q|} \sum_{q \in Q} P@k(q).$$

Внешняя оценка качества отображалась на публичном лидерборде, где организаторы вычисляли Precision@10 по скрытой тестовой разметке. Поэтому Public LB следует рассматривать как внешнюю оценку качества на скрытых данных, но не как полностью независимую научную валидацию, поскольку при множественных отправках он подвержен эффекту подстройки под публичную часть теста.

Для контролируемой проверки гипотез дополнительно использовалась локальная валидация. Из размеченной обучающей части формировался speaker-disjoint-сплит, в котором говорящие в обучении и валидации не пересекались. На валидационной выборке воспроизводился тот же протокол: по L2-нормализованным эмбеддингам вычислялись косинусные сходства, исключалось самосовпадение, выбирались k ближайших соседей и рассчитывался локальный Precision@k.

Базовый контур инференса строился как задача поиска ближайших соседей в пространстве эмбеддингов. Каждой аудиозаписи (x) сопоставлялся векторный признак

$$z(x) = \frac{f_\theta(x)}{|f_\theta(x)|2},$$

где $f\theta$ — параметризованный акустический энкодер, а L_2 -нормализация переводит сравнение записей в угловую геометрию. Сходство между запросом q и кандидатной записью g вычислялось косинусной мерой

$$s(q, g) = z(q)^\top z(g).$$

Для каждого запроса формировалось ранжирование всех остальных записей тестового множества по убыванию s(q,g), после чего из рассмотрения исключалось самосовпадение g=q, и в итоговый список включались первые k элементов ранжированного набора.

В качестве базового способа ранжирования использовался прямой поиск ближайших соседей по косинусному сходству. Более сложные процедуры, включая графовую постобработку, локальное масштабирование расстояний, распространение меток и схемы псевдоразметки, рассматривались как надстройки над этим базовым поисковым контуром. Это обеспечивало сопоставимость экспериментов: во всех сериях сохранялись единые входные данные, единая внешняя метрика и единое правило формирования итогового списка соседей, а варьировались только способ построения эмбеддингов и алгоритм последующего переупорядочивания кандидатов [1, 16].

На рисунке 4 далее представлена динамика значений Public LB на протяжении всего цикла разработки решения.

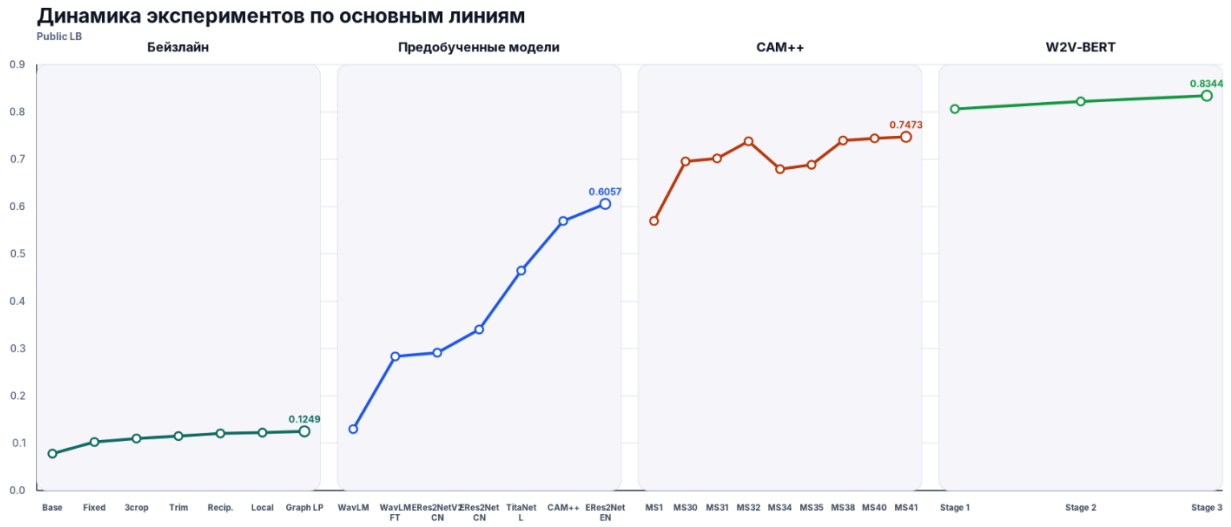

Рис. 4. Динамика публичных результатов по семействам моделей и ключевым вехам развития системы.

В общей структуре экспериментов можно выделить четыре основные линии развития. Первая линия связана с построением исходного бейзлайна и последующей графовой постобработкой ранжирования, то есть с исследованием того, насколько качество поиска определяется не только самим эмбеддингом, но и способом формирования списка соседей. Вторая линия относится к сравнению различных предобученных акустических моделей и выбору наиболее перспективной архитектурной основы для дальнейшей адаптации. Третья линия представляет собой углублённое развитие ветви CAM++, в которой исследовались режимы дообучения, методы формирования признаков, псевдоразметка и аугментации. Наконец, четвёртая линия связана с адаптацией крупной мультиязычной модели W2V-BERT 2.0 и поэтапным усложнением схемы её дообучения. Далее каждая линия экспериментов будет рассмотрена более подробно [4-9, 17].

Линия базовой модели.

Исходная линия экспериментов была построена как двухэтапный конвейер. На первом этапе выполнялся прямой поиск ближайших соседей в пространстве векторных представлений записей. На втором этапе исследовалась графовая постобработка ранжирования. Такое разделение принципиально важно, поскольку позволяет отдельно оценивать качество акустического представления и качество процедуры формирования итогового списка соседей [1, 16].

Пусть каждой записи x_i сопоставлен вектор признаков $h_i \in \mathbb{R}^d$, где размерность d определяется используемой акустической моделью. В проведённых экспериментах для сильных ветвей использовались, в частности, размерности d=512 для CAM++ и official ERes2Net и d=256 для W2V-BERT stage 3. Перед поиском соседей векторы нормировались по евклидовой норме [4-6, 17]:

$$z_i = \frac{h_i}{|h_i| * 2}.$$

После этого сходство между двумя записями вычислялось как косинусное сходство

$$s * ij = z_i^\top z_j.$$

Для нормированных векторов такое упорядочивание эквивалентно ранжированию по косинусному расстоянию и монотонно эквивалентно ранжированию по евклидову расстоянию. Тем самым базовый контур поиска сводился к точному выбору ближайших соседей по значениям $z_i^\top z_j$ с исключением самосовпадения.

При этом в системе использовалось несколько разных параметров числа соседей, отвечающих за разные стадии обработки. Для графовой части строился более широкий список кандидатов, размер которого является гиперпараметром. На его основе далее формировался граф соседства: для распространения меток использовались 10 ближайших соседей, для проверки взаимности ребра — список top-20, а резервное ранжирование после графовой коррекции строилось на первых 100 кандидатах. Такая иерархия параметров позволяла не смешивать целевую метрику (P@10) с более широким внутренним пулом кандидатов, необходимым для устойчивой графовой переоценки.

На первом этапе в качестве бейзлайна рассматривался прямой поиск соседей по косинусному сходству. Однако уже на этой стадии проявлялась типичная для высокоразмерных пространств проблема hubness: отдельные записи слишком часто попадали в списки ближайших соседей для большого числа запросов [1].

Для снижения влияния данной проблемы для каждого кандидата j сначала вычислялась характеристика локальной плотности как среднее значение его первых двадцати оценок сходства:

$$\mu_j = \frac{1}{20} \sum_{r=1}^{20} s_{j,(r)},$$

где $s_{j,(r)}$ — r-е по величине сходство в списке ближайших соседей узла j. Затем по всем узлам тестового пула рассчитывался стандартизованный показатель

$$\zeta_j = \frac{\mu_j - \bar{\mu}}{\sigma_\mu}.$$

На стадии резервного переупорядочивания исходное сходство модифицировалось по правилу

$$\tilde{s}_{ij} = s_{ij} + 0.03\,\mathbf{1}[(i,j)] - 0.02\,\zeta_j$$

Первое добавочное слагаемое повышает приоритет взаимных соседей, а второе уменьшает приоритет узлов с аномально высокой локальной плотностью. Тем самым графовая коррекция в данной работе представляет собой не классическое локальное масштабирование, а практическую схему компенсации хабов за счёт учёта взаимности и плотности [1].

В более поздних вариантах этой линии дополнительно исследовалась мягкая коррекция по предполагаемому классу внутри уже сформированного пула кандидатов. Для пары (i,j) исходная оценка дополнялась небольшими бонусами за согласованность наиболее вероятных классов в верхних позициях локального ранжирования. Однако данная модификация являлась не базовым, а расширенным вариантом графового хвоста; в собственно бейзлайне ключевую роль играли именно косинусное ранжирование, поправка за взаимность и поправка на локальную плотность.

Следующий шаг состоял в переходе от независимого ранжирования к графовому уточнению сообществ. На публичном тесте истинные идентификаторы говорящих неизвестны, поэтому по графу не распространяются классы говорящих. Вместо этого каждая запись тестового пула на нулевой итерации получает собственную временную метку [16]:

$$\ell_i^{(0)} = i,$$

после чего на графе взаимных ближайших соседей выполняется детерминированное взвешенное обновление:

$$\ell_i^{(t+1)} = \arg\max_c \sum_{j \in N(i),, \ell_j^{(t)} = c} w_{ij},$$

где N(i) — множество взаимных соседей узла i, а w_{ij} — вес ребра, определяемый сходством между соответствующими записями. В базовом варианте веса рёбер совпадали с оценками сходства на этих рёбрах; в более сложных модификациях могли добавляться небольшие поправки за общих соседей или ранговое согласование. По существу эта процедура строит псевдокластеры внутри текущего тестового пула и потому корректнее описывается как транздуктивное графовое уточнение поиска, а не как классификация по известным классам [16].

Принципиально важно, что полученные метки сообществ не заменяли поиск соседей напрямую. После сходимости алгоритма сначала строилось резервное ранжирование по скорректированным значениям $\tilde{s}_{ij}$, а затем применялось правило приоритетного выбора кандидатов из того же сообщества. Для запроса i обозначим через

$$R_i = (j_1, \ldots, j_{100})$$

упорядоченный список первых ста кандидатов по убыванию $\tilde{s}_{ij}$, а через

$$C_i = , j \in R_i : \ell_j = \ell_i,$$

множество кандидатов из того же сообщества. Тогда множество приоритетных кандидатов определялось как

$$A_i = \begin{cases} C_i, & \text{if } 5 \le |C_i^*| \le 120 \text{ and } |C_i| \ge 3, \\ \varnothing, & \text{else.} \end{cases}$$

где $C_i^* = j : \ell_j = \ell_i$ — полное сообщество запроса во всём тестовом пуле. Иными словами, кандидаты из того же сообщества поднимались вверх только тогда, когда размер сообщества лежал в разумных пределах и внутри первых ста кандидатов находилось не менее трёх его представителей.

Таблица 1. Эксперименты линии бейзлайна.

Эксперимент	Основное изменение	Public LB
Organizer baseline	исходная отправная точка	0.0779
`baseline_fixed_participants`	исправление протокола обрезки, детерминированный вывод, точный поиск соседей	0.1024
`B2_raw_3crop`	усреднение по трём окнам	0.1098
`B4_trim_3crop`	аккуратное удаление лишней тишины перед извлечением признаков	0.1150
`B7_trim_3crop_reciprocal_top50`	взаимные соседи и повторное ранжирование	0.1206
`B8_trim_3crop_reciprocal_local_scaling`	локальное масштабирование против hubness	0.1223
`C4_b8_labelprop_mutual10`	распространение информации по графу взаимных соседей	0.1249
`organizer_baseline_e20_earlystop_epoch10_center`	более длительное обучение той же базовой модели	0.1046

Таблица 1 показывает, что в пределах базовой линии больший выигрыш давали не дополнительные эпохи обучения, а улучшения на этапе построения соседей и вывода. Рост от 0.0779 до 0.1249 был достигнут главным образом за счёт исправления протокола, многократного извлечения признаков, удаления тишины, учёта взаимности соседства, подавления hubness и

графового распространения информации. Поэтому графовая постобработка была включена в финальный экспериментальный конвейер.

Второй вывод этой линии имеет статистическую природу. В рамках проведённых экспериментов попытки обучать компактные модели с нуля на данных соревнования давали ограниченный прирост: CAM++ с нуля достигал 0.1753, ERes2NetV2 — 0.2410, а пересчитанный CAM++ с официальным фронтендом — 0.2597. Этот результат указывает на то, что для данной постановки адаптация сильного внешнего энкодера оказалась более эффективной, чем обучение компактной модели с нуля [4-6].

Линия выбора предобученной модели.

Выбор предобученной модели в данной работе рассматривался не только как задача поиска наилучшего значения целевой метрики, но и как задача выбора такого типа акустических представлений, который наиболее устойчиво переносится на скрытое распределение тестовой части. В сравнение были включены, с одной стороны, относительно компактные модели, изначально ориентированные на задачи распознавания и верификации говорящего, а с другой — крупные речевые модели общего назначения, обученные в режиме самоконтроля. К первой группе относились архитектуры семейств TDNN и Res2Net, включая CAM++, English ERes2Net, Chinese ERes2Net, Chinese ERes2NetV2 и NVIDIA TitaNet-Large; ко второй — WavLM как универсальный речевой энкодер и W2V-BERT 2.0 как крупная мультиязычная модель представления речи, допускающая последующую адаптацию под целевую задачу. Архитектурно эти модели заметно различаются: CAM++ опирается на плотную TDNN-схему с контекстно-зависимым маскированием и многоуровневым агрегированием

признаков, ERes2Net и ERes2NetV2 усиливают извлечение локальных и глобальных речевых характеристик, а TitaNet использует одномерные разделимые свёртки, механизмы перенастройки каналов и внимательное статистическое агрегирование. При этом прямое сопоставление специализированных моделей для говорящего с универсальными самоконтролируемыми энкодерами требует осторожной интерпретации, поскольку последние, вообще говоря, предполагают отдельную процедуру адаптации к прикладной постановке. Сравнительные результаты исследованных предобученных моделей приведены в таблице 2 [4-10, 17].

Таблица 2. Сравнение метрик предобученных моделей.

Модель	Размер модели, млн параметров	Характер применения	Public LB
English ERes2Net	6.6	прямой перенос	0.6057
CAM++	7.2	прямой перенос	0.5695
NVIDIA TitaNet-Large	25.3	прямой перенос	0.4646
Chinese ERes2Net large	22.5	прямой перенос	0.3403
Chinese ERes2NetV2 common	17.8	прямой перенос	0.2911
WavLM	94	прямой перенос	0.1297
WavLM fine-tuned	94	адаптация на данных соревнования	0.2833

Результаты таблицы 2 показывают, что в режиме прямого переноса наилучшее значение публичного лидерборда продемонстрировала модель English ERes2Net, тогда как CAM++ заняла второе место, уступив ей по внешней метрике, но оставаясь в числе наиболее сильных и при этом существенно более компактных решений. Это означает, что по данным данного сравнения нельзя делать вывод о безусловном преимуществе CAM++ с точки зрения качества прямого переноса; напротив, таблица фиксирует

лидерство English ERes2Net именно в рассматриваемом нулевом или почти нулевом адаптационном сценарии. Вместе с тем CAM++ сохраняла практическую привлекательность как компромисс между качеством, размером модели и вычислительной экономичностью, что и сделало её разумной кандидатурой для дальнейшего углублённого дообучения [4, 5].

Одновременно результаты таблицы показывают, что специализированные модели, изначально обученные для задач распознавания или верификации говорящего, в режиме прямого переноса заметно превосходят универсальные самоконтролируемые речевые энкодеры общего назначения. Однако этот вывод следует интерпретировать осторожно. Такое сопоставление не является полностью симметричным, поскольку универсальные модели типа WavLM в общем случае рассчитаны не на непосредственное использование в задаче поиска говорящего, а на последующую адаптацию под прикладную постановку. Поэтому низкий результат WavLM при прямом переносе не следует трактовать как свидетельство слабости самоконтролируемых речевых представлений как таковых; корректнее говорить о том, что без специальной адаптации они уступают специализированным акустическим моделям в данной задаче [8].

Дополнительное подтверждение этому даёт строка с дообученным WavLM: по сравнению с прямым переносом качество заметно возрастает, хотя и остаётся существенно ниже результатов лучших speaker-specific моделей. Следовательно, сама по себе таблица указывает не на непригодность универсальных речевых энкодеров, а на необходимость более содержательной и глубокой процедуры адаптации. Именно по этой причине дальнейшее исследование было организовано по двум направлениям: с одной стороны, продолжалось развитие компактной специализированной ветви

CAM++, а с другой — отдельно рассматривалась более сложная схема адаптации крупных предобученных речевых моделей [8].

Линия обучения CAM++.

Линия CAM++ стала центральной компактной ветвью исследования и позволила перейти от сильной предобученной модели к устойчивой конкурентоспособной системе. Её развитие удобно описывать через четыре взаимосвязанных блока: воспроизведение исходного тракта признаков и аккуратную адаптацию модели, использование жёсткой псевдоразметки, акустические аугментации и сглаживание в пространстве весов [4].

Первым принципиальным шагом в этой линии стало не просто уменьшение шага обучения, а восстановление корректного соответствия между предобученными весами и тем трактом признаков, на котором эти веса были получены. Под «официальным фронтендом» в данной ветви понимается конкретная схема извлечения признаков, совпадающая с официальной реализацией CAM++: для каждого аудиосигнала строились Kaldi-совместимые логарифмические энергии в полосах Mel с помощью fbank, использовалось 80 полос, параметр дизеринга был равен нулю, а после извлечения признаков выполнялась только нормализация по среднему внутри записи,

$$\tilde{X} = X - \frac{1}{T}\sum_{t=1}^{T} X_t,$$

где $X \in \mathbb{R}^{T\times 80}$ — матрица признаков записи, а T — число временных кадров. Важно подчеркнуть, что в этой ветви не использовались ни скользящая нормализация, ни удаление пауз на стадии публичного вывода;

тем самым модель получала на вход именно тот тип признаков, для которого была изначально настроена официальная реализация [4].

Короткие записи дополнялись повторением до длительности 6 с, а длинные на стадии публичного вывода представлялись тремя равномерно расположенными сегментами по 6 с последующим усреднением эмбеддингов:

$$z(x) = \frac{1}{3} \sum_{m=1}^{3} z_m(x),$$

где $z_m(x)$ — векторное представление m-го сегмента записи (x).

После восстановления корректного тракта признаков основное развитие ветви шло в направлении аккуратной адаптации модели на данных соревнования. Здесь использовался малый шаг обучения, что позволяло не разрушать исходную структуру предобученного пространства и одновременно подстраивать модель к специфике рассматриваемого корпуса.

Следующий крупный блок был связан с псевдоразметкой. В данной работе использовалась жёсткая графовая псевдоразметка полного публичного тестового пула. Источником псевдометок служила сильная модель-учитель MS31, то есть дообученая CAM++ с добавлением акустических аугментаций. Для всех записей публичного теста сначала строился расширенный граф соседства по эмбеддингам учителя, после чего на нём выполнялось выделение устойчивых сообществ с использованием взаимных соседей, числа общих соседей и штрафа на чрезмерно большие сообщества. В псевдоразмеченный набор попадали только сообщества размера от 8 до 80 записей. Каждому такому сообществу присваивался новый искусственный

идентификатор говорящего, то есть использовались именно жёсткие псевдометки, а не мягкие распределения по классам [11].

Итоговый псевдоразмеченный набор включал 104 361 запись. После объединения с исходной обучающей выборкой получался смешанный корпус с 14 021 классом, из которых 10 848 соответствовали исходным размеченным говорящим, а 3 173 — псевдокластерам, построенным на публичном тестовом пуле. При этом устойчивость самодообучения обеспечивалась не индивидуальной вероятностью доверия для каждой записи, а консервативностью всего рецепта в целом: использовался сильный учитель, графовое выделение сообществ, жёсткое ограничение размеров кластеров, сбалансированное формирование пакетов по говорящим, малый шаг обучения и небольшое число эпох. Такое сочетание мер снижало риск каскадного накопления ошибок, характерного для некачественной псевдоразметки. Вместе с тем данный этап следует интерпретировать именно как транздуктивное использование неразмеченных тестовых данных, поскольку псевдометки строились на полном публичном тестовом пуле; следовательно, его переносимость за пределы соревновательного контура требует отдельной проверки [11].

Третий блок был связан с акустическими аугментациями. Их применение в линии CAM++ не являлось произвольной регуляризацией, а мотивировалось результатами предварительного анализа данных, показавшего различие обучающей и публичной тестовой частей по длительности активной речи и по высокочастотным характеристикам сигнала. Поэтому в данной ветви использовались преобразования, моделирующие шум, реверберацию и изменение темпа сигнала. Формально их можно записать в виде

$$x_{\text{noise}}(t) = x(t) + n(t),$$
$$x_{\text{reverb}}(t) = (h * x)(t),$$
$$x_{\text{speed}}(t) = x(\alpha t),$$

где n(t) — добавляемый шум, h — импульсная характеристика помещения, а α — коэффициент изменения скорости воспроизведения. В рассматриваемой линии такие преобразования улучшали устойчивость модели к вариативности условий записи и использовались уже после того, как была восстановлена корректная совместимость официального энкодера с официальным трактом признаков [12].

Наконец, в поздней фазе этой ветви было проверено сглаживание в пространстве весов, близкое к идее усреднения нескольких близких решений. Если $\theta_1, \ldots, \theta_M$ обозначают параметры нескольких близких по качеству моделей, то сглаженные веса могут быть записаны как

$$\theta_{\text{avg}} = \sum_{m=1}^{M} \lambda_m \theta_m, \qquad \lambda_m \geq 0, \qquad \sum_{m=1}^{M} \lambda_m = 1.$$

Смысл такого шага состоит в уменьшении чувствительности итоговой модели к случайным флуктуациям отдельного запуска без увеличения стоимости вывода. В линии CAM++ эта процедура дала небольшой положительный эффект относительно сильной базовой конфигурации, однако данный выигрыш следует интерпретировать осторожно: он наблюдался в конкретной серии экспериментов и не заменяет систематическую проверку по нескольким инициализациям [13].

Таблица 3. Сравнение основных стадий CAM++.

Эксперимент	Интерпретация	Public LB
MS1	исходный CAM++ без адаптации	0.5695
MS30	малый шаг обучения + официальный фронтенд	0.6953
MS31	усиленные аугментации	0.7018
MS32	фильтрованная псевдоразметка	0.7379
MS34	жёсткая очистка псевдометок	0.6791
MS35	взвешенная псевдоразметка	0.6884
MS38	сглаживание весов	0.7396
MS40	маршрутизация хвоста post hoc	0.7441
MS41	слабый бонус по классам внутри графа	0.7473

Таблица 3 показывает, что ключевой прирост в линии CAM++ был достигнут на двух этапах: при переходе к официальному тракту признаков и при добавлении графово отфильтрованной псевдоразметки. Рост от MS1 к MS30 указывает, что решающим фактором стало восстановление корректного соответствия между предобученными весами и входными признаками, тогда как аугментации в MS31 дали уже более умеренное улучшение. Наиболее заметный последующий вклад обеспечила фильтрованная псевдоразметка в MS32, повысившая Public LB до 0,7379.

Особый интерес представляют отрицательные результаты MS34 и MS35. Жёсткая очистка псевдометок и их взвешивание ухудшили качество по сравнению с MS32. Это позволяет предположить, что слишком агрессивная фильтрация уменьшала разнообразие псевдоразмеченного набора, могла исключать редких говорящих и усиливать смещение модели-учителя. Тем самым в данной задаче умеренно шумная, но более разнообразная псевдоразметка оказалась полезнее, чем чрезмерно очищенный набор.

Сглаживание весов в MS38 дало лишь небольшой выигрыш относительно MS32, поэтому его следует интерпретировать осторожно: результат согласуется с идеей усреднения близких решений, но требует проверки на нескольких независимых запусках. Последние улучшения в MS40 и MS41 были получены уже за счёт более тонкой графовой постобработки, а не за счёт радикального изменения самой модели.

Линия W2V-BERT.

Наилучшие результаты в данной серии экспериментов были получены при использовании W2V-BERT 2.0 — крупного мультиязычного самосупервизионного речевого энкодера, впервые представленного в 2023 году в рамках модели SeamlessM4T. В открытой реализации данный энкодер основан на Conformer-архитектуре, содержит около 580–600 млн параметров и предобучен на 4,5 млн часов неразмеченной речи более чем на 143 языках. В связи с тем, что W2V-BERT 2.0 представляет собой универсальную предобученную модель речевых представлений, а не специализированную систему поиска говорящего, его применение в настоящей работе требовало дополнительной адаптации к целевой задаче, включавшей многослойную агрегацию признаков, параметрически эффективное дообучение и использование функции потерь с угловым разделением классов [9, 10, 17].

В работе использовалась трехстадийная схема адаптации. На первой стадии обучалась надстройка над предобученным энкодером, преобразующая скрытые представления в эмбеддинг говорящего. На второй стадии в модель добавлялись механизмы более гибкой адаптации, включая Multi-Feature Aggregation и параметрически экономное дообучение части слоев. На третьей стадии выполнялось финальное согласование признакового пространства и

классификационной головы, после чего конфигурация использовалась для инференса. Такая организация обучения позволяла последовательно повышать качество без полного переобучения всей сети с нуля [14, 17].

Пусть $H_l \in \mathbb{R}^{T \times d_l}$ — последовательность скрытых состояний l-го слоя W2V-BERT 2.0, где T — число временных шагов. Для использования информации нескольких уровней представления вводятся адаптеры $A_l(\cdot)$, приводящие выходы выбранных слоев к общей размерности d:

$$\widetilde{H}l = A_l(H_l), \qquad \widetilde{H}l \in \mathbb{R}^{T \times d}.$$

После этого признаки нескольких слоев объединяются:

$$U = \mathrm{Concat}\big(\widetilde{H}l_1, \widetilde{H}l_2, \ldots, \widetilde{H}l_m\big),$$

$$U \in \mathbb{R}^{T \times md}.$$

Такое объединение позволяет использовать одновременно низкоуровневую акустическую и более абстрактную фонетико-содержательную информацию. Далее к последовательности U применяется статистический pooling с вниманием, формирующий фиксированный вектор записи:

$$\mu = \sum t = 1^T \alpha_t U_t,$$

$$\sigma = \sqrt{\sum_{t=1}^{T} \alpha_t (U_t - \mu)^2},$$

$$e = W[\mu; \sigma] + b,$$

где α_t — нормированные коэффициенты внимания, а e — итоговый эмбеддинг говорящего [17].

Для уменьшения числа обучаемых параметров использовалась LoRA-адаптация части матриц внимания. В этом случае обучаемое обновление веса задается в низкоранговой форме:

$$W = W_0 + \frac{\alpha}{r} BA,$$

где W_0 — замороженная предобученная матрица, $B \in \mathbb{R}^{d \times r}$ и $A \in \mathbb{R}^{r \times k}$ — обучаемые низкоранговые множители, r — ранг разложения, α — коэффициент масштабирования. Такая параметризация позволяет адаптировать крупную модель без полного обновления всех ее весов [14].

Для обучения эмбеддингов использовалась функция потерь типа ArcFace с аддитивным угловым зазором. Пусть x_i — нормализованный эмбеддинг i-й записи, а w_j — нормализованный вес j-го класса. Тогда θ_j обозначает угол между x_i и w_j, а функция потерь имеет вид [15]:

$$\mathcal{L} - \frac{1}{N}\sum_{i=1}^{N}\log\frac{\exp\left(s\cos(\theta_{y_i}+m)\right)}{\exp\left(s\cos(\theta_{y_i}+m)\right)+\sum_{j\neq y_i}\exp\left(s\cos\theta_j\right)},$$

где m — угловой зазор, s — масштабный коэффициент. Такая постановка способствует лучшему разделению классов в угловом пространстве и обычно оказывается полезной для задач speaker verification и speaker retrieval.

Таблица 4. Результаты обучения W2V-BERT.

Эксперимент	Интерпретация	Public LB
`W2V1k`	первая стадия W2V-BERT	0.8062
`W2V1l`	вторая стадия W2V-BERT	0.8222
`W2V1j`	третья стадия W2V-BERT	0.8344

По публичному лидерборду данная линия показала последовательное улучшение качества. Кроме того, на локальной верификационной оценке от второй к третьей стадии наблюдалось снижение ошибок: EER = 0.015162 и minDCF = 0.102414 на второй стадии против EER = 0.014806 и minDCF = 0.093501 на третьей. Таким образом, линия W2V-BERT 2.0 продемонстрировала наилучшие результаты среди рассмотренных подходов, полученные значения показывают, что перенос крупного мультиязычного предобученного энкодера с контролируемой downstream-адаптацией является наиболее перспективным направлением в рамках данного исследования [9, 17].

Финальное решение.

Финальное решение в настоящей работе определяется как композиция третьей стадии адаптации W2V-BERT 2.0 и процедуры графовой постобработки C4 tail. Именно эта связка обеспечила наилучший результат на публичном лидерборде: Public LB = 0.8344 [1, 16, 17].

На этапе инференса для каждой аудиозаписи строились три детерминированных фрагмента длительностью 6 с. Для каждого фрагмента вычислялся эмбеддинг говорящего; далее эмбеддинги усреднялись, и полученный вектор записи повторно нормировался. После этого по всему множеству записей публичной тестовой части выполнялся точный поиск ближайших соседей по cosine similarity с сохранением расширенного списка кандидатов для каждой записи. Поверх полученного графа соседей применялась процедура C4 tail, включавшая учет взаимных соседств, распространение меток и итоговое переранжирование кандидатов. Финальный список соседей для каждой записи формировался как объединение графово согласованных кандидатов и резервного косинусного ранжирования. Именно эта конфигурация рассматривалась как окончательный вариант системы [1, 16].

Перспективы дальнейшего развития.

Несмотря на достигнутый уровень качества, полученные результаты указывают на наличие существенного резерва для дальнейшего совершенствования системы. Одним из наиболее приоритетных направлений представляется снижение вычислительной сложности модели при сохранении ее дискриминативной способности. В первую очередь речь идет о применении дистилляции знаний, при которой информация, усвоенная крупной моделью-учителем, переносится в более компактную архитектуру-студент. В сочетании с этим целесообразно исследовать методы структурного и неструктурного прунинга, направленные на сокращение числа параметров и ускорение инференса. Для практического применения системы данное направление имеет принципиальное значение, поскольку

использованная конфигурация на основе W2V-BERT 2.0 характеризуется высокой ресурсоемкостью [17].

Вторым важным направлением является расширение обучающего корпуса. Результаты экспериментов показывают, что качество модели существенно зависит от масштаба и разнообразия данных, используемых на этапе адаптации. Следовательно, дальнейшее дообучение на большем объеме размеченной речи, а также более аккуратное привлечение псевдоразмеченных данных, должно способствовать росту устойчивости и обобщающей способности модели. Особый интерес представляет увеличение представленности редких говорящих, коротких записей и акустически сложных примеров, поскольку именно эти области пространства данных, по-видимому, связаны с наибольшим числом ошибок.

Отдельной задачей является систематический подбор гиперпараметров. В рамках текущего исследования значительная часть конфигурационных решений принималась в условиях ограниченного экспериментального бюджета, что естественно для соревновательного сценария, но недостаточно для окончательной оптимизации метода. В дальнейшем целесообразно провести контролируемое исследование влияния скорости обучения, размера батча, длины аудиофрагмента, параметров функции потерь, конфигурации LoRA, числа агрегируемых слоев, а также интенсивности и состава аугментаций. Аналогичная настройка требуется и для графовой постобработки, включая параметры построения графа, локального масштабирования и распространения меток.

Кроме того, перспективным направлением является углубленное исследование работы с неразмеченными данными. Полученные результаты

показывают, что эффект псевдоразметки определяется не только объемом автоматически размеченных примеров, но и качеством процедуры их отбора. В этой связи необходимо более подробно изучить стратегии фильтрации псевдометок, учет их надежности, применение мягких меток и различные режимы взвешивания псевдоразмеченных наблюдений в функции потерь. Такая постановка позволит перейти от эмпирического использования псевдоразметки к более строго обоснованной полусупервизируемой схеме обучения [11].

Список источников

1. Schnitzer D., Flexer A., Schedl M., Widmer G. Local and Global Scaling Reduce Hubs in Space [Электронный ресурс] // Journal of Machine Learning Research. 2012. Vol. 13. P. 2871-2902. URL: https://jmlr.org/papers/v13/schnitzer12a.html (дата обращения: 19.04.2026).

2. McFee B., Raffel C., Liang D. et al. librosa: Audio and Music Signal Analysis in Python [Электронный ресурс] // Proceedings of the 14th Python in Science Conference. 2015. P. 18-25. URL: https://proceedings.scipy.org/articles/Majora-7b98e3ed-003 (дата обращения: 19.04.2026).

3. Dubnov S. Generalization of Spectral Flatness Measure for Non-Gaussian Linear Processes [Электронный ресурс] // IEEE Signal Processing Letters. 2004. Vol. 11, no. 8. P. 698-701. URL: https://dub.ucsd.edu/Papers/SPL.pdf (дата обращения: 19.04.2026).

4. Wang H., Zheng S., Chen Y., Cheng L., Chen Q. CAM++: A Fast and Efficient Network for Speaker Verification Using Context-Aware Masking [Электронный ресурс]. 2023. URL: https://arxiv.org/abs/2303.00332 (дата обращения: 19.04.2026).

5. Chen Y., Zheng S., Wang H., Cheng L., Chen Q., Zhang S., Li J. An Enhanced Res2Net with Local and Global Feature Fusion for Speaker Verification [Электронный ресурс]. 2023. URL: https://arxiv.org/abs/2305.12838 (дата обращения: 19.04.2026).

6. Chen Y., Zheng S., Wang H., Cheng L., Chen Q., Zhang S., Li J. ERes2NetV2: Boosting Short-Duration Speaker Verification Performance with Computational Efficiency [Электронный ресурс]. 2024. URL: https://arxiv.org/abs/2406.02167 (дата обращения: 19.04.2026).

7. Koluguri N. R., Park T., Ginsburg B. TitaNet: Neural Model for Speaker Representation with 1D Depth-Wise Separable Convolutions and Global Context [Электронный ресурс]. 2021. URL: https://arxiv.org/abs/2110.04410 (дата обращения: 19.04.2026).

8. Chen S., Wang C., Chen Z. et al. WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing [Электронный ресурс]. 2021. URL: https://arxiv.org/abs/2110.13900 (дата обращения: 19.04.2026).

9. Barrault L., Chung Y.-A., Meglioli M. C. et al. SeamlessM4T: Massively Multilingual & Multimodal Machine Translation [Электронный ресурс]. 2023. URL: https://arxiv.org/abs/2308.11596 (дата обращения: 19.04.2026).

10. Gulati A., Qin J., Chiu C.-C. et al. Conformer: Convolution-augmented Transformer for Speech Recognition [Электронный ресурс]. 2020. URL: https://arxiv.org/abs/2005.08100 (дата обращения: 19.04.2026).

11. Amini M.-R., Feofanov V., Pauletto L. et al. Self-Training: A Survey [Электронный ресурс]. 2022. URL: https://arxiv.org/abs/2202.12040 (дата обращения: 19.04.2026).

12. Snyder D., Chen G., Povey D. MUSAN: A Music, Speech, and Noise Corpus [Электронный ресурс]. 2015. URL: https://arxiv.org/abs/1510.08484 (дата обращения: 19.04.2026).

13. Wortsman M., Ilharco G., Li M. et al. Model Soups: Averaging Weights of Multiple Fine-Tuned Models Improves Accuracy without Increasing Inference Time [Электронный ресурс]. 2022. URL: https://arxiv.org/abs/2203.05482 (дата обращения: 19.04.2026).

14. Hu E. J., Shen Y., Wallis P. et al. LoRA: Low-Rank Adaptation of Large Language Models [Электронный ресурс]. 2021. URL: https://arxiv.org/abs/2106.09685 (дата обращения: 19.04.2026).

15. Deng J., Guo J., Yang J., Xue N., Kotsia I., Zafeiriou S. ArcFace: Additive Angular Margin Loss for Deep Face Recognition [Электронный ресурс] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019. P. 4690-4699. URL:

https://openaccess.thecvf.com/content_CVPR_2019/html/Deng_ArcFace_Additive_Angular_Margin_Loss_for_Deep_Face_Recognition_CVPR_2019_paper.html (дата обращения: 19.04.2026).
16. Raghavan U. N., Albert R., Kumara S. Near Linear Time Algorithm to Detect Community Structures in Large-Scale Networks [Электронный ресурс] // Physical Review E. 2007. Vol. 76, no. 3. Art. 036106. URL: https://arxiv.org/abs/0709.2938 (дата обращения: 19.04.2026).
17. Li Z., Cheng M., Li M. Enhancing Speaker Verification with w2v-BERT 2.0 and Knowledge Distillation guided Structured Pruning [Электронный ресурс]. 2025. URL: https://arxiv.org/abs/2510.04213 (дата обращения: 19.04.2026).