Квадрицепс. Криптонит. Тембр.

Кейс: разработать модель/пайплайн распознавания диктора по голосу, устойчивый к шумам, реверберации, записи с большого расстояния и искажениям канала связи.

Команда

Максим Клещенок

Специалист более другого уровня.

Рустам Сахабудтинов

Сеньор-Фронтендер. Скиллы Асфальтоукладка и газовая сварка на глубине 300 м. Аватарку прикладываю.

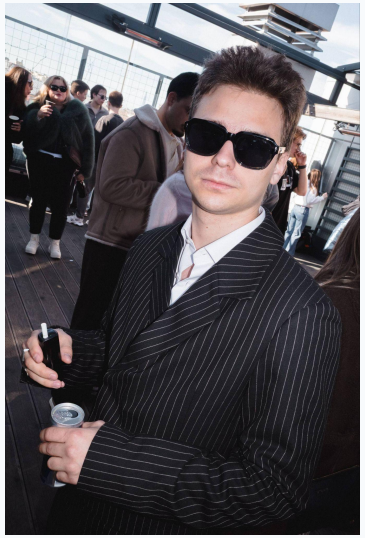

Роман Громов

Сеньор-Ученый. Скиллы Флористика, копаю септики, дорого. В 500 метрах от вас.

Алексей Галиев

Сеньор-Бэкендер. Скиллы приготовление чебупиццы альденте, грузовые перевозки на дальние расстояния

EDA

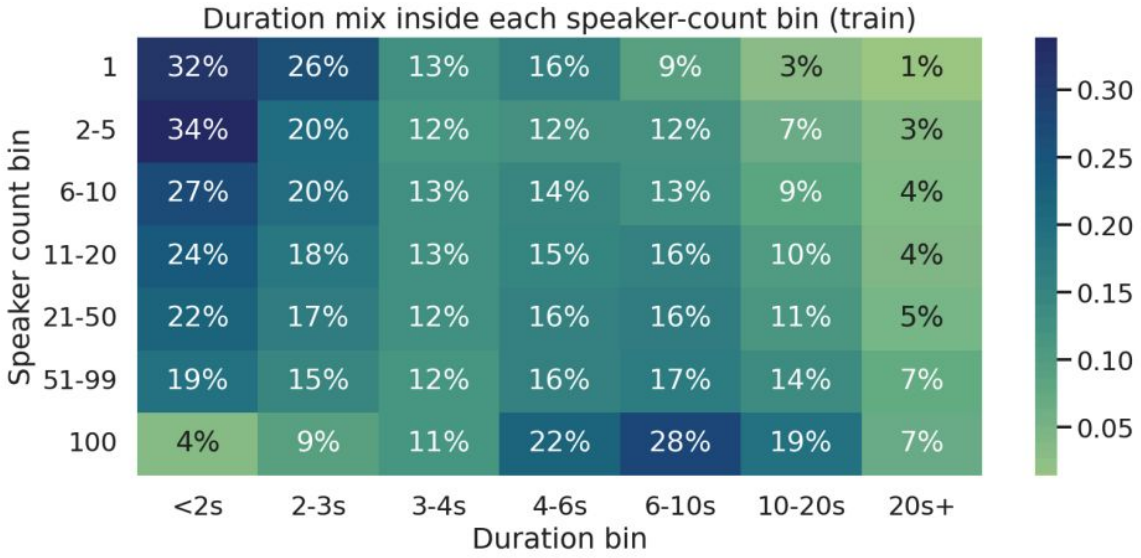

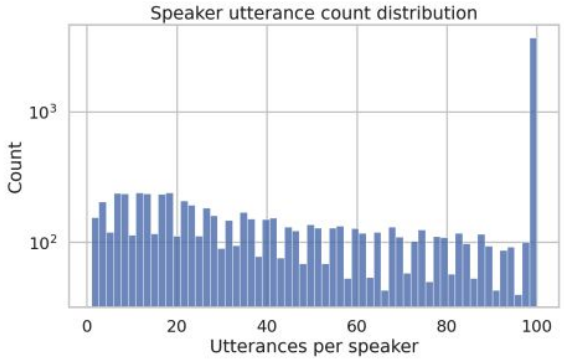

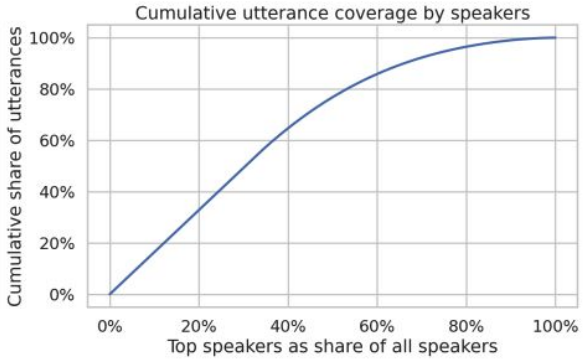

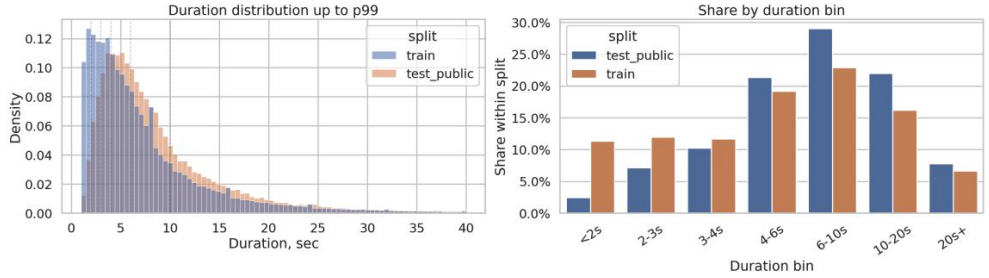

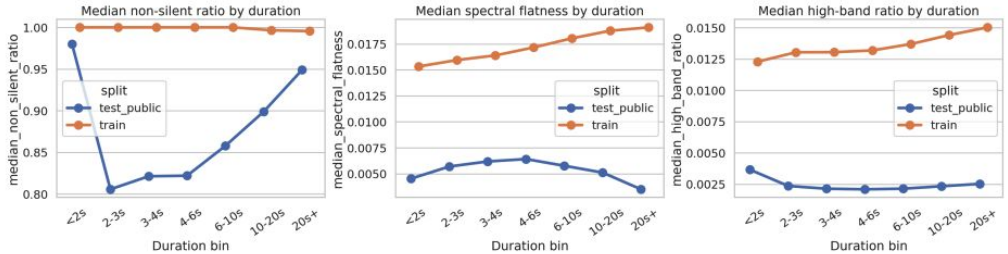

дисбаланс по спикерам

test длиннее

акустический сдвиг

Динамика экспериментов

Использованные методы

3-crop

Три детерминированных окна по 6 секунд.

Trim silence

Аккуратное удаление лишних пауз перед извлечением признаков.

Cosine kNN

Точный поиск ближайших соседей в нормированном пространстве.

C4 / graph tail

Взаимные соседи, local scaling и label propagation.

CAM++ adaptation

Официальный frontend, аугментации и псевдоразметка.

W2V-BERT adaptation

MFA, LoRA, attentive pooling и ArcFace.

Линия бейзлайна

Эксперимент	Изменение	Public LB
Organizer baseline	исходная точка	0.0779
baseline_fixed_participants	фикс протокола + точный kNN	0.1024
B2_raw_3crop	усреднение по 3 окнам	0.1098
B4_trim_3crop	удаление лишней тишины	0.1150
B8_local_scaling	борьба с hubness	0.1223
C4_labelprop	графовое распространение	0.1249

+60%
рост к baseline

Важно

Графовый tail вошел в финальный конвейер.

Ключевой вывод

Даже в базовой линии качество росло прежде всего за счет retrieval-хвоста, а не за счет более долгого обучения.

Сравнение предобученных моделей

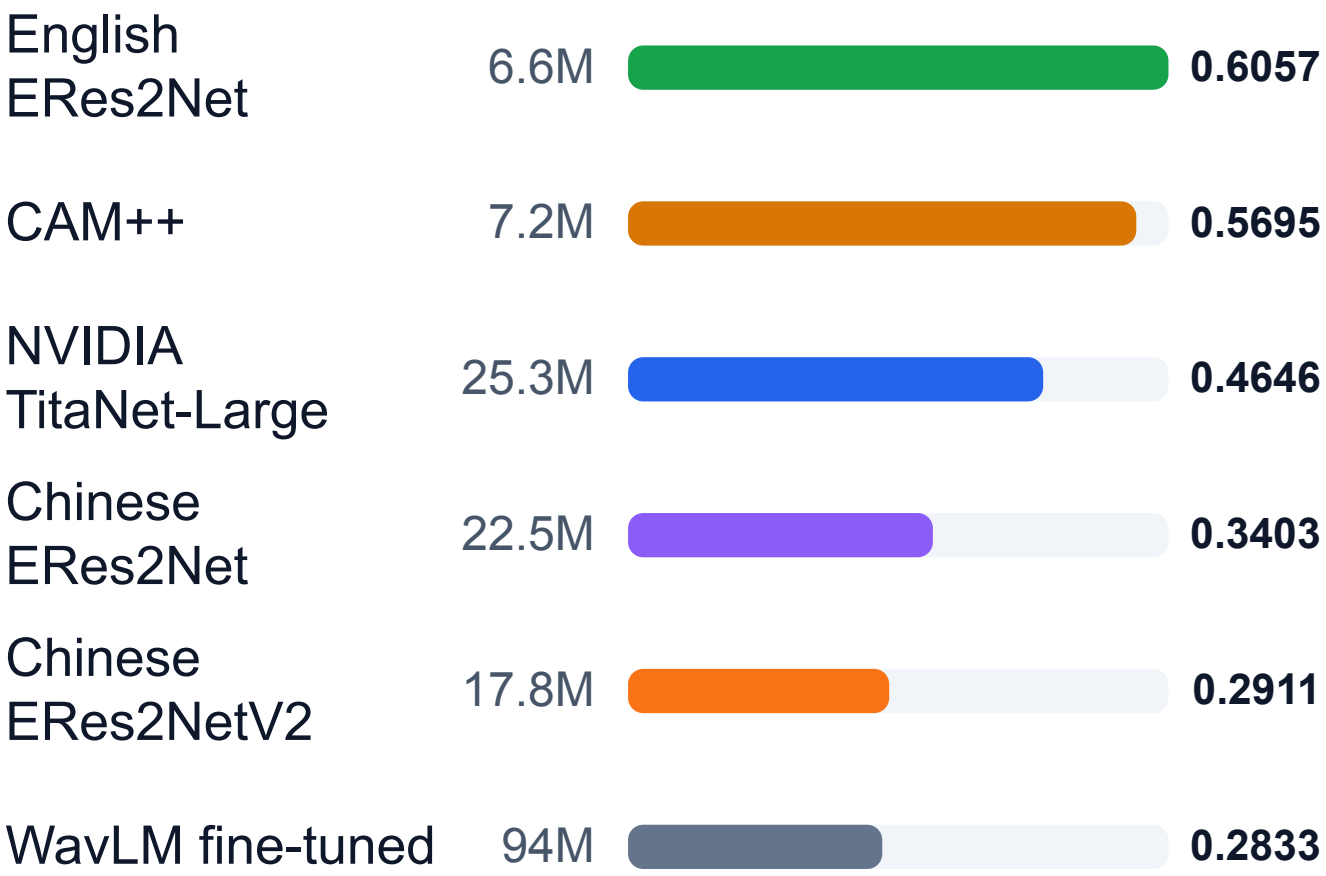

Best zero-shot

English ERes2Net показал лучший результат в режиме прямого переноса.

Почему CAM++ остался важным

Почти столь же сильный старт, но гораздо удобнее для компактной адаптации и дальнейших экспериментов.

Вывод

Крупные SSL-энкодеры без специальной адаптации уступали speaker-specific моделям.

Линия CAM++

Эксперимент	Интерпретация	Public LB
MS1	исходный CAM++	0.5695
MS30	малый LR + официальный frontend	0.6953
MS31	усиленные аугментации	0.7018
MS32	фильтрованная псевдоразметка	0.7379
MS34	жесткая очистка псевдометок	0.6791
MS35	взвешенная псевдоразметка	0.6884
MS38	сглаживание весов	0.7396
MS41	слабый бонус по классам	0.7473

0.7379 MS32: псевдоразметка

0.7473 MS41: пик CAM++

Научно ценный отрицательный результат

MS34 и MS35 показали, что слишком агрессивная очистка может снижать diversity и усиливать bias учителя.

Финальное решение

Лучшая конфигурация: staged adaptation крупного мультиязычного энкодера и графово согласованная постобработка ранжирования.

0.8344

лучший Public LB

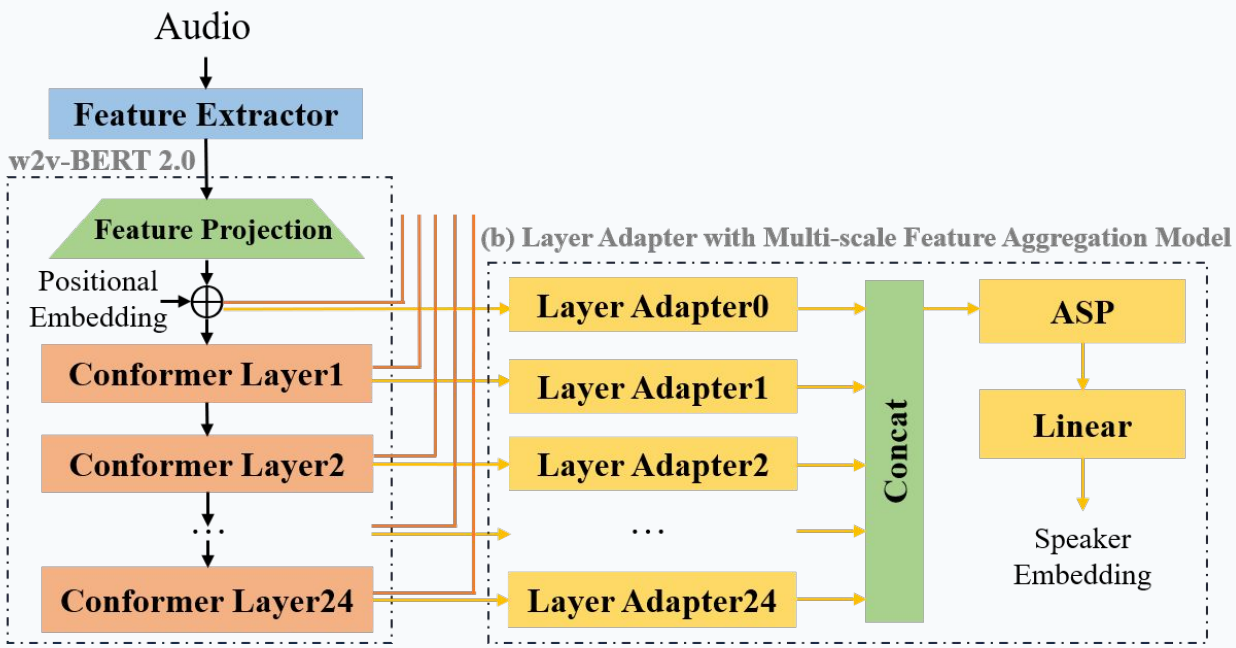

Описание бэкбоуна

Input

waveform
3 окна × 6 с

W2V-BERT 2.0

мультиязычный
Conformer
≈580–600M

MFA

агрегация
нескольких
скрытых слоев

Pooling

attentive
stats pooling

Head

256-d
embedding
+ ArcFace

Почему это сработало

Большой SSL-бэкбоун дал сильное исходное представление, а downstream-адаптация перевела его в speaker space.

Что добавлено

MFA, attentive pooling, LoRA и ArcFace-голова.

143+

языков
предобучения

4.5M ч

объем речи в
pretrain

Описание первого этапа обучения

Stage 1: обучение speaker head поверх предобученного энкодера.

Что обучается

Адаптеры, pooling и ArcFace-голова. Backbone в основном заморожен.

Зачем нужен этап

Перевести универсальные речевые признаки в пространство признаков говорящего без резкой перестройки всей модели.

Backbone

freeze

Adapters

align dims

Pooling

stats

ArcFace

margin loss

Описание второго этапа обучения

Stage 2: добавление более гибкой адаптации через Multi-Feature Aggregation и parameter-efficient tuning.

Что добавляется	Эффект
Агрегация нескольких скрытых слоев и LoRA для части attention-матриц.	Более богатый speaker embedding и лучшее обобщение на скрытое распределение теста.

слой l1

low-level

слой l2

phonetic

слой lm

abstract

MFA

fuse

Описание третьего этапа обучения

Stage 3: финальное согласование признакового пространства и головы перед итоговым inference.

Что происходит

Доводка head и embedding-space, лучшее разделение классов в угловой геометрии.

Почему это финал

Именно эта стадия показала лучшие значения и вошла в итоговую конфигурацию с C4 tail.

Embedding

final space

ArcFace

margin

3-crop

stable clips

C4

graph tail

Таблица с метриками

Финальная ветвь W2V-BERT последовательно улучшает и leaderboard, и локальные verification-метрики.

Стадия	Public LB	EER	minDCF
W2V1k · Stage 1	0.8062	—	—
W2V1l · Stage 2	0.8222	0.015162	0.102414
W2V1j · Stage 3	0.8344	0.014806	0.093501

+0.0122

LB vs Stage 2

-0.000356

EER

-0.008913

minDCF

Интерпретация

Поздние стадии улучшают не только Public LB, но и локальные verification-показатели, то есть прогресс согласован по двум типам оценки.

Таблица сравнения скоростей

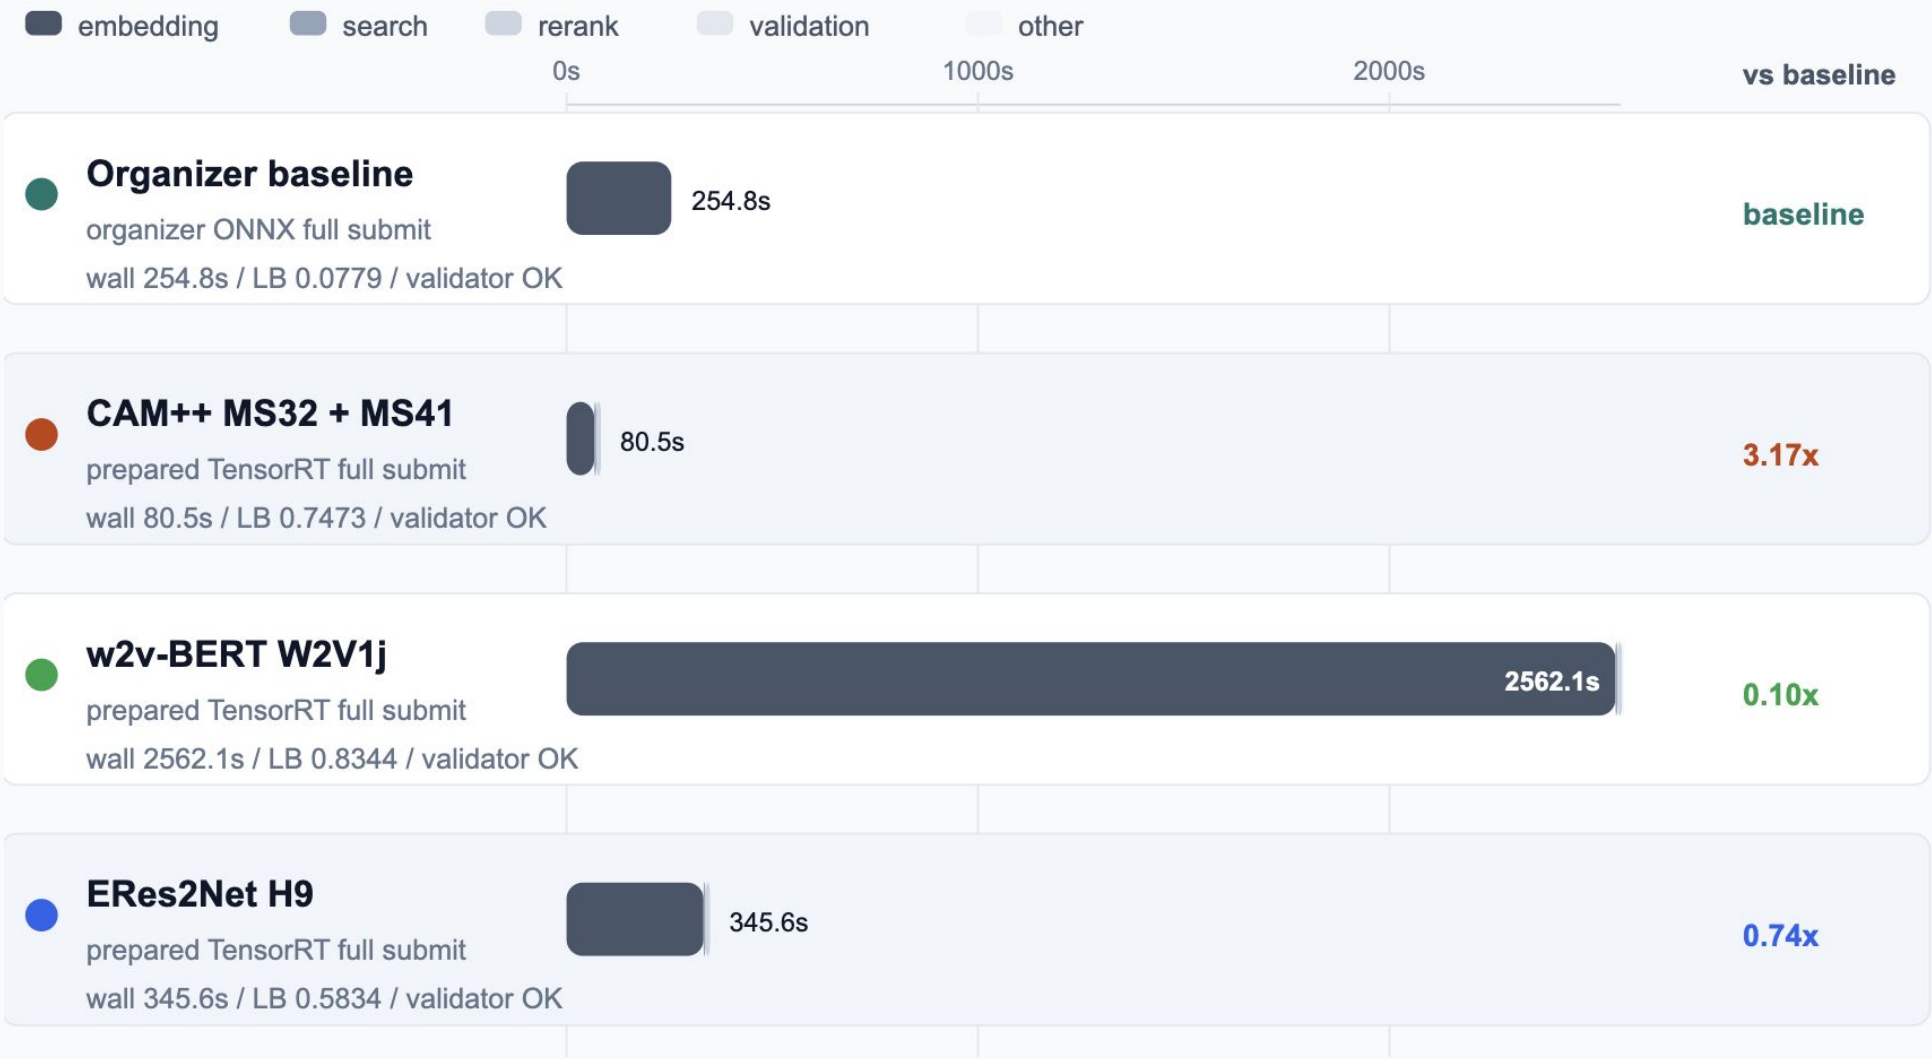

Возможные улучшения

Дистилляция и pruning

Перенести качество крупной модели в компактного студента.

Расширение корпуса

Больше размеченной и аккуратно псевдоразмеченной речи.

Систематический HPO

LR, batch, длина фрагмента, LoRA, ArcFace и графовые параметры.

Лучшее semi-supervised

Надежность псевдометок, мягкие метки и более строгая фильтрация.

Спасибо за внимание, это был квадрицепс

W2V-BERT 2.0

C4 tail

0.8344